

**LAPORAN AKHIR
KECERDASAN BUATAN
PREDIKSI TEMPERATUR PENDINGIN MOTOR LISTRIK DENGAN
K-NEIGHBOURS REGRESSOR**



KELOMPOK 5

Rizqi Dian Anggara	22/496470/TK/54398
Muhammad Billy Bhadrika	22/504577/TK/55193
Bintang Putra Megantara	22/500086/TK/54794

**PROGRAM STUDI TEKNIK FISIKA
DEPARTEMEN TEKNIK NUKLIR DAN TEKNIK FISIKA
FAKULTAS TEKNIK
UNIVERSITAS GADJAH MADA
YOGYAKARTA
2024**

DAFTAR ISI

DAFTAR ISI.....	2
DAFTAR GAMBAR.....	3
DAFTAR TABEL.....	4
BAB I PENDAHULUAN.....	5
1.1. Latar Belakang.....	5
1.2. Deskripsi Masalah.....	5
1.3. Batasan Masalah.....	6
1.4. Tujuan.....	6
BAB II TINJAUAN PUSTAKA.....	7
2.1. Interquartile Range Method.....	7
2.2. K-Neighbors Regressor.....	7
2.3. Histogram Gradient Boosting Regressor.....	8
BAB III PEMBAHASAN.....	10
3.1. Business Understanding.....	10
3.2. Data Understanding.....	10
3.3. Data Preparation.....	12
3.4. Feature Engineering.....	14
3.5. Modelling.....	16
3.6. Evaluasi Model.....	16
BAB IV PENUTUP.....	18
4.1. Kesimpulan.....	18
4.2. Potensi Pengembangan.....	18
DAFTAR PUSTAKA.....	21
LAMPIRAN.....	22
Lampiran 1. URL Video Presentasi.....	22
Lampiran 2. URL Video Demo Project.....	22
Lampiran 3. Code.....	22

DAFTAR GAMBAR

Gambar 1. Metode IQR.....	7
Gambar 2. Deskripsi Statistik Dataset.....	12
Gambar 3. NaN, Null, dan Duplicated Data.....	13
Gambar 4. Jumlah Data Setelah Cleaning.....	14
Gambar 5. Matriks Korelasi Antar Fitur.....	15
Gambar 6. Feature Importance.....	15
Gambar 7. K-Neighbors Regressor.....	16
Gambar 8. Histogram Gradient Boosting Regressor (HistGBR).....	16
Gambar 9. Parameter Evaluasi Model.....	17
Gambar 10. Komparasi Prediksi dan Nilai Sebenarnya.....	17
Gambar 11. Skema Implementasi.....	19

DAFTAR TABEL

Tabel 1. Variabel Data.....	11
-----------------------------	----

BAB I

PENDAHULUAN

1.1. Latar Belakang

Motor listrik menjadi komponen penting dalam berbagai bidang industri, dimulai dari manufaktur dan otomotif. Dalam beberapa dekade terakhir, perkembangan teknologi menjadi tren yang sangat menjanjikan hingga diklaim dapat menggantikan motor bakar mengingat motor listrik selaras dengan pembangunan yang ramah lingkungan. Popularitas motor listrik didorong oleh perkembangan dari kendaraan listrik yang lebih unggul dalam hal efisiensi energi.

Namun, salah satu tantangan utama dalam perkembangan motor listrik adalah perubahan suhu yang belum dapat diatasi dengan baik. Perubahan suhu yang signifikan yang tidak sesuai dengan operasi optimal dari motor listrik hanya akan menghambat kinerja dari sistem itu sendiri. Perubahan suhu yang drastis akan berdampak langsung pada fluks listrik yang dihasilkan dari perputaran magnet yang ada pada sistem motor listrik. Semakin tinggi suhu yang ada pada sistem akan menurunkan kualitas dan efisiensi kerja dari motor listrik.

Oleh karena itu, diperlukan sistem kendali yang dapat menjaga temperatur optimal dari sebuah motor listrik guna meningkatkan efisiensi dan ketahanan dari komponen motor listrik seperti baterai yang berfungsi untuk menyimpan tenaga yang dihasilkan. Berdasar hal tersebut, optimasi desain dalam isolasi termal motor listrik beserta sistem pendinginan menjadi salah satu solusi yang kerap digunakan untuk mengatasi perubahan suhu yang terjadi.

Salah satu upaya yang dapat digunakan dalam mengoptimasi kinerja dari sistem pendingin dari motor listrik adalah dengan melakukan prediksi temperatur pada motor listrik yang akan digunakan sebagai basis operasi dari sistem pendinginan. Pada pengembangannya sendiri, penggunaan kecerdasan buatan maupun *machine learning* menjadi satu hal yang sesuai guna melakukan sistem prediksi suhu.

1.2. Deskripsi Masalah

Kendati motor listrik dirancang untuk beroperasi pada berbagai situasi, tantangan terbesar adalah pengelolaan suhu menjadi fokus utama. Beberapa masalah utama yang kerap terjadi pada motor listrik antara lain.

1. Minimnya akurasi kerja dari sistem pendinginan dalam menjaga suhu optimal pada motor listrik
2. Kurangnya analisis kondisi operasi secara *real-time* mengingat motor listrik harus bekerja pada waktu yang sangat panjang

Dua permasalahan tadi dapat menyebabkan biaya operasional dan pemeliharaan melonjak yang diakibatkan oleh penurunan efisiensi konsumsi energi dan resiko kegagalan sistem yang tinggi.

1.3. Batasan Masalah

Dalam kajian kali ini, diberikan beberapa batasan dalam merancang model prediksi sistem pendinginan ini.

1. Dataset berasal dari sumber yang terpercaya seperti data eksperimen pada satu universitas
2. Proyek akan berfokus pada prediksi suhu pendingin pada motor listrik
3. Metode analisis yang digunakan berbasis kecerdasan buatan dengan memanfaatkan konsep statistika

1.4. Tujuan

Adapun tujuan dari proyek ini adalah

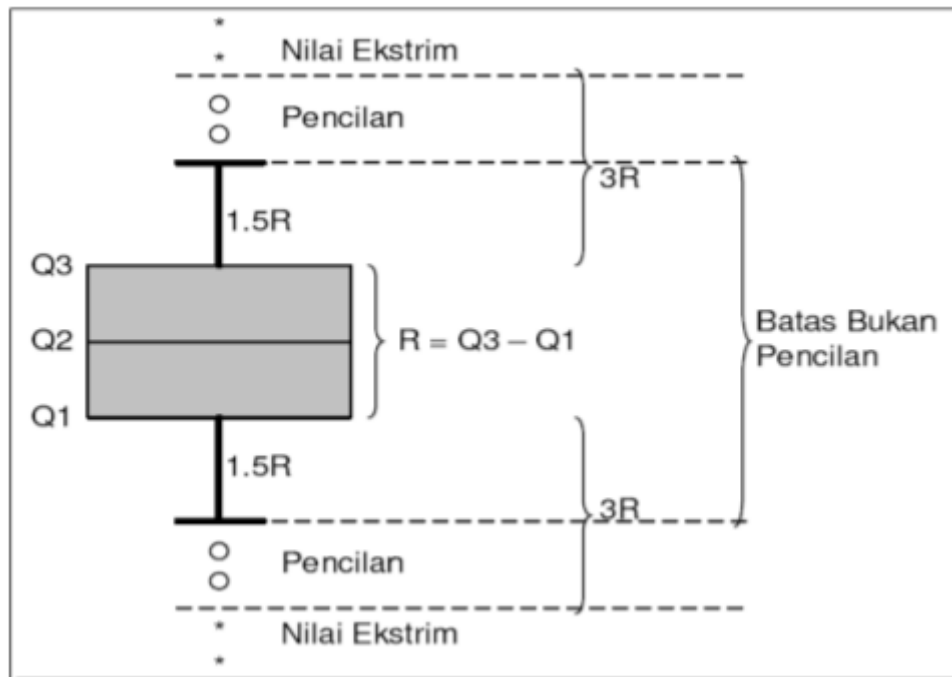
1. Memprediksi suhu pendingin bekerja
2. Melakukan eksplorasi dari pemanfaatan kecerdasan buatan dan *machine learning* pada prediksi temperatur pendingin motor listrik
3. Meningkatkan efisiensi konsumsi energi dengan menjaga operasi motor listrik pada temperatur optimalnya

BAB II

TINJAUAN PUSTAKA

2.1. Interquartile Range Method

Interquartile Range (IQR) merupakan metode statistik yang digunakan dalam mengukur persebaran data dengan fokus pada rentang di antara quartile 1 dan 3. IQR dihitung dengan mengurangi 25% data (Q_1) dan 75% data (Q_3). Dalam konteks pengembangan kecerdasan buatan, IQR menjadi salah satu metode yang berguna untuk menghilangkan pencilan data outlier.



Gambar 1. Metode IQR

Metode IQR dalam menghilangkan outlier memiliki prinsip kerja dengan mendeteksi data di luar boxplot tersebut. Dapat dirumuskan dengan $Outlier = Q_1 - 1,5 \times IQR, Q_3 + 1,5 \times IQR$ dengan $IQR = Q_3 - Q_1$.

2.2. K-Neighbors Regressor

K-Neighbors Regressor merupakan algoritma *supervised learning* yang didasarkan pada suatu instance untuk memprediksi nilai yang kontinu. Prinsip kerja dari algoritma ini adalah dengan mencari nilai k tetangga terdekat berdasarkan matriks jarak. Beberapa parameter penting dalam algoritma antara lain:

1. `n_neighbors`

Parameter yang digunakan menentukan jumlah tetangga terdekat yang akan digunakan. Nilai yang terlalu kecil akan mengakibatkan model overfitting, sementara nilai yang terlalu besar akan membuat model menjadi underfitting.

2. weights

Parameter untuk mengatur kontribusi setiap tetangga yang akan dihitung. Pilihan umum adalah uniform sehingga setiap tetangga memiliki bobot yang sama. Adapaun pilihan yang kedua adalah berdasarkan *distance* yaitu tetangga dengan jarak yang lebih dekat memiliki bobot

3. metric

Parameter yang digunakan untuk menentukan jarak dari masing masing data. Pemilihan metrik akan mempengaruhi kualitas prediksi terutama pada dataset dengan fitur yang berbeda skalanya. Beberapa metrik yang dapat dilakukan adalah euclidean, minkowski, manhattan, dll.

2.3. Histogram Gradient Boosting Regressor

Histogram Gradient Boosting Regressor (HistGBR) merupakan algoritma supervised learning berdasarkan ensemble yang memanfaatkan decision tree guna menangani masalah regresi. Alih - alih menggunakan semua data secara langsung, algoritma ini membagi fitur fitur menjadi histogram guna mempercepat proses pembelajaran. Beberapa parameter yang kerap digunakan pada algoritma ini antara lain.

1. learning_rate

Dalam proses pembelajarannya, tentunya diperlukan menentukan besar kontribusi decision tree dalam pembentukan suatu model yang besarnya mampu mempengaruhi akurasi dan kecepatan pelatihan. Nilai *learning_rate* yang kecil mampu meningkatkan akurasi namun memerlukan lebih banyak iterasi dan pengulangan, sedangkan nilai yang besar akan mempercepat pelatihan namun model yang dihasilkan beresiko terjadi overfitting.

2. max_iter

max_iter menjadi salah satu parameter yang digunakan untuk menentukan jumlah pohon yang akan digunakan untuk membangun sebuah model dalam

ensemble. Semakin banyak iterasi tentunya akan semakin kompleks model yang akan dibangun

3. `max_depth` atau `max_leaf_nodes`

Digunakan untuk membatasi ukuran pohon dalam mencegah terjadinya overfitting. Parameter ini membantu model tetap seimbang antara bias dan variansinya.

4. `L2_regularization`

Menambahkan regulasi pada model untuk mencegah kasus overfitting model terutama pada dataset dengan fitur lebih dari satu.

5. `early_stopping`

Menghentikan pelatihan lebih awal jika tidak ada peningkatan performa pada data validasi serta mampu mengurangi resiko overfitting dan waktu pelatihan.

BAB III

PEMBAHASAN

3.1. Business Understanding

Dalam industri modern, motor listrik kerap digunakan dalam berbagai aplikasi kritis seperti sistem transportasi, produksi dan manufaktur. Kinerja motor listrik sangat bergantung pada pengelolaan suhu yang efektif. Ketika suhu melebihi batas aman, komponen penting seperti stator, magnet, dan pendingin dapat mempengaruhi dari kinerja dan efisiensi. Untuk meminimalisasi kerusakan dan memaksimalkan umur operasional motor, diperlukan sistem yang dapat memprediksi suhu secara akurat dan real-time. Dataset yang ada menyediakan parameter operasional seperti tegangan, arus, kecepatan motor, torsi, serta suhu dari berbagai komponen motor listrik.

Berdasarkan hal tersebut, pengembangan sistem prediksi temperatur pendingin dalam menjaga suhu optimal motor listrik memiliki beberapa keuntungan dari perspektif bisnis, antara lain.

1. Mengurangi resiko downtime akibat overheating motor listrik
2. Memperpanjang umur operasional motor listrik dengan menjaga suhu tetap optimal
3. Menurunkan konsumsi energi sistem pendingin dengan pendekatan berbasis data
4. Meminimalkan biaya pemeliharaan dan penggantian suku cadang
5. Mendukung transisi menuju industri yang lebih ramah lingkungan dan optimal dengan pemanfaatan sistem prediksi menggunakan kecerdasan buatan.

3.2. Data Understanding

Dataset Electric Motor Temperature merupakan data dari hasil pengamatan suatu percobaan dari Department di Paderborn University. Pengambilan data dilakukan dengan mengambil sampel yang bekerja pada frekuensi 2 Hz dengan total waktu sekitar ± 138 sd 185 jam dengan beberapa orang penguji yang dilengkapi dengan profile_id dan setiap profile_id mampu melakukan pengukuran selama satu hingga enam jam lamanya. Berdasarkan hal tersebut, dataset ini memiliki 1330816 baris data dan 13 kolom dengan detail sebagai berikut.

Tabel 1. Variabel Data

No	Variabel	Penjelasan	Tipe Data
1	u_q	Tegangan yang dihasilkan pada koordinat q (V)	float64
2	u_d	Tegangan yang dihasilkan pada koordinat d (V)	float64
3	i_d	Arus yang dihasilkan pada koordinat d (A)	float64
4	i_q	Arus yang dihasilkan pada koordinat q (A)	float64
5	coolant	Temperatur dari pendingin yang digunakan pada electric motor (°C)	float64
6	stator_winding	Temperatur dari lilitan pada bagian stator (°C)	float64
7	stator_yoke	Temperatur dari yoke pada bagian stator (°C)	float64
8	stator_tooth	Temperatur dari gigi stator (°C)	float64
9	motor_speed	Kecepatan putaran dari motor (rpm)	float64
10	torque	Torsi motor yang dihasilkan (Nm)	float64
11	pm	Temperatur pada permanen magnet (°C)	float64
12	ambient	Temperatur dari lingkungan kerja motor (°C)	float64
13	profile_id	Profile dari orang yang melakukan pengecekan	int64

Dalam memahami suatu data tentunya diperlukan informasi statistik dari persebaran data yang ada. Berikut deskripsi statistik persebaran data electrical motor temperature.

	u_q	coolant	stator_winding	u_d	stator_tooth	motor_speed
count	1.330816e+06	1.330816e+06	1.330816e+06	1.330816e+06	1.330816e+06	1.330816e+06
mean	5.427900e+01	3.622999e+01	6.634275e+01	-2.513381e+01	5.687858e+01	2.202081e+03
std	4.417323e+01	2.178615e+01	2.867206e+01	6.309197e+01	2.295223e+01	1.859663e+03
min	-2.529093e+01	1.062375e+01	1.858582e+01	-1.315304e+02	1.813398e+01	-2.755491e+02
25%	1.206992e+01	1.869814e+01	4.278796e+01	-7.869090e+01	3.841601e+01	3.171107e+02
50%	4.893818e+01	2.690014e+01	6.511013e+01	-7.429755e+00	5.603635e+01	1.999977e+03
75%	9.003439e+01	4.985749e+01	8.814114e+01	1.470271e+00	7.558668e+01	3.760639e+03
max	1.330370e+02	1.015985e+02	1.413629e+02	1.314698e+02	1.119464e+02	6.000015e+03

	i_d	i_q	pm	stator_yoke	ambient	torque	profile_id
	1.330816e+06	1.330816e+06	1.330816e+06	1.330816e+06	1.330816e+06	1.330816e+06	1.330816e+06
	-6.871681e+01	3.741278e+01	5.850678e+01	4.818796e+01	2.456526e+01	3.110603e+01	4.079306e+01
	6.493323e+01	9.218188e+01	1.900150e+01	1.999100e+01	1.929522e+00	7.713575e+01	2.504549e+01
	-2.780036e+02	-2.934268e+02	2.085696e+01	1.807669e+01	8.783478e+00	-2.464667e+02	2.000000e+00
	-1.154061e+02	1.095863e+00	4.315158e+01	3.199033e+01	2.318480e+01	-1.374265e-01	1.700000e+01
	-5.109376e+01	1.577401e+01	6.026629e+01	4.562551e+01	2.479733e+01	1.086035e+01	4.300000e+01
	-2.979688e+00	1.006121e+02	7.200837e+01	6.146083e+01	2.621702e+01	9.159718e+01	6.500000e+01
	5.189670e-02	3.017079e+02	1.136066e+02	1.011480e+02	3.071420e+01	2.610057e+02	8.100000e+01

Gambar 2. Deskripsi Statistik *Dataset*


3.3. Data Preparation

Dataset yang diambil dari suatu percobaan tentunya memiliki karakteristik data yang cenderung *messy* sehingga diperlukan suatu data *processing* guna membuat model dengan akurasi yang tinggi tanpa dipengaruhi oleh data yang kurang berkorelasi. Adapun jenis data yang tidak berkorelasi atau berpengaruh pada model antara lain. Pertama, Not a Number (NaN) Values yang menunjukkan bahwa data yang hilang. Kedua, Null yang merujuk pada suatu data yang tidak ada, kosong, maupun tidak terdefiniskan. Baik NaN dan Null akan mempengaruhi model karena mengurangi jumlah informasi serta berpotensi menimbulkan bias yang tidak tepat. Ketiga, Duplicated values merupakan data yang memiliki nilai duplikat sehingga mengganggu representasi dari suatu data dan mengurangi efisiensi komputasi.


	null	duplicated	NaN Values
u_q	0	0	0
coolant	0	0	0
stator_winding	0	0	0
u_d	0	0	0
stator_tooth	0	0	0
motor_speed	0	0	0
i_d	0	0	0
i_q	0	0	0
pm	0	0	0
stator_yoke	0	0	0
ambient	0	0	0
torque	0	0	0
profile_id	0	0	0

Gambar 3. NaN, Null, dan *Duplicated Data*

Hal kedua yang perlu diperhatikan adalah pencilan data (*outlier*), outlier, pencilan data merupakan data yang signifikan berbeda dari sebagian besar data lainnya dalam suatu dataset. Pencilan dapat berupa data yang lebih besar atau jauh lebih kecil dibandingkan nilai lainnya sehingga membuat pola data menjadi kacau. Salah satu metode menghilangkan pencilan data dengan menggunakan metode Interquartile Range (IQR) yaitu metode yang berfokus pada rentang data pada Q1 sampai Q3 sehingga data di luar batas $1,5Q_1$ dan $1,5Q_3$ akan diabaikan serta dihapus pada dataset.



Gambar 3 (a). Kondisi Raw Data



Gambar 3 (b).Kondisi Data Clean

Setelah penghilangan pencilan dengan IQR didapati bahwa jumlah data berkurang sesuai dengan banyaknya pencilan yang ada. Data berkurang dari 1330816 data menjadi 1262850 data yang menunjukkan bahwa outlier


#	Column	Non-Null Count	Dtype
---	-----	-----	-----
0	u_q	1262850 non-null	float64
1	coolant	1262850 non-null	float64
2	stator_winding	1262850 non-null	float64
3	u_d	1262850 non-null	float64
4	stator_tooth	1262850 non-null	float64
5	motor_speed	1262850 non-null	float64
6	i_d	1262850 non-null	float64
7	i_q	1262850 non-null	float64
8	pm	1262850 non-null	float64
9	stator_yoke	1262850 non-null	float64
10	ambient	1262850 non-null	float64
11	torque	1262850 non-null	float64
12	profile_id	1262850 non-null	int64

Gambar 4. Jumlah Data Setelah Cleaning


3.4. Feature Engineering

Proses penentuan fitur menjadi salah satu proses penting dalam membangun suatu model kecerdasan buatan karena setiap fitur memiliki korelasinya masing-masing sehingga diperlukan penentuan fitur mana saja yang memiliki

korelasi paling kuat. Dalam proses *feature engineering* pemanfaatan matriks korelasi dan *feature importance* menjadi salah satu langkah dalam menentukan fitur mana saja yang digunakan.



Gambar 5. Matriks Korelasi Antar Fitur



Gambar 6. Feature Importance

Dari kedua metode *feature engineering* baik matriks korelasi dan feature importance memberikan hasil yang kuat untuk variabel stator_yoke dan stator_winding terhadap variabel target yaitu coolant.

3.5. Modelling

Tahap selanjutnya adalah dengan pembuatan model yang diawali dengan membagi dataset menjadi dua yaitu data train beserta test dengan komposisi 5% data testing dan 95% data training dengan menggunakan library *train test split* dari scikit learn. Terdapat dua model yang akan digunakan dalam membangun sistem prediksi yaitu K-Neighbours Regressor dan Histogram Gradient Boosting Regressor yang bertujuan untuk melihat model mana yang paling sesuai dengan dataset yang ada dengan parameter pada gambar di bawah.

```
# Model pertama
KNN = KNeighborsRegressor(n_neighbors=35,metric="manhattan")
KNN.fit(x_train,y_train)
models.loc['train_mse','KNN'] = mean_squared_error(y_pred=KNN.predict(x_train), y_true = y_train)
```

Gambar 7. K-Neighbors Regressor

```
# Model Kedua
HGB = HistGradientBoostingRegressor(random_state=32)
HGB.fit(x_train,y_train)
models.loc['train_mse','HGB'] = mean_squared_error(y_pred=HGB.predict(x_train), y_true = y_train)
```

✓ 7.0s

Gambar 8. Histogram Gradient Boosting Regressor (HistGBR)

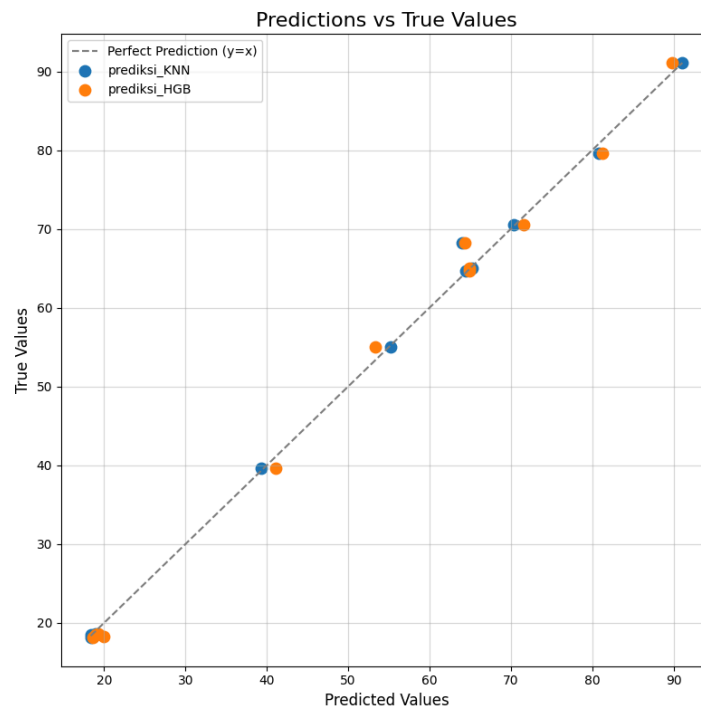
3.6. Evaluasi Model

Dengan algoritma regressor, evaluasi model dapat dilakukan dengan 3 parameter. Pertama, menggunakan koefisien korelasi (R^2) dengan nilai yang mendekati 1 menunjukkan korelasi positif yang mendekati ideal, nilai yang mendekati -1 menunjukkan korelasi negatif yang mendekati ideal, dan nilai yang mendekati 0 menunjukkan tidak adanya korelasi antar variabel. Kedua, Mean Squared Error (MSE) yang merupakan rata rata kuadrat kesalahan dari suatu persebaran data. Ketiga, Mean Absolute Error (MAE) yang merupakan rata-rata kesalahan absolut dari persebaran data yang ada. Berikut hasil evaluasi masing masing parameter pada kedua model.

	train_mse	test_mse	train_mae	test_mae	train_r2	test_r2
KNN	10.916977	11.810447	1.604656	1.665233	0.977054	0.975228
HGB	13.493161	13.746464	1.952323	1.962391	0.971639	0.971167

Gambar 9. Parameter Evaluasi Model

Selain dengan parameter error yang ada pada Gambar x. evaluasi dapat dilakukan dengan melakukan komparasi antara nilai prediksi yang dihasilkan oleh model yang telah dibangun dengan nilai yang sebenarnya. Pada grafik di bawah didapati bahwa hasil prediksi menunjukkan nilai yang mendekati nilai sebenarnya dengan prediksi K-Neighbors Regressor yang lebih akurat dibanding HistGBR.



Gambar 10. Komparasi Prediksi dan Nilai Sebenarnya

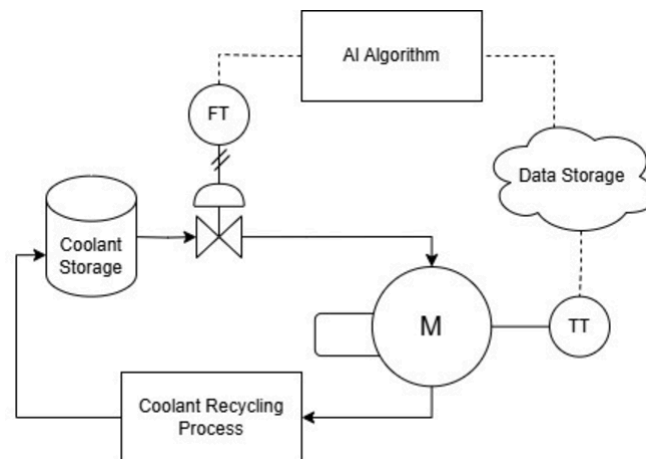
BAB IV

PENUTUP

4.1. Kesimpulan

Menyoroti pentingnya penggunaan kecerdasan buatan untuk meningkatkan pengelolaan suhu motor listrik yang menjadi tantangan utama dalam operasional industri modern. Dengan mengadopsi algoritma K-Neighbors Regressor, sistem prediksi ini berhasil memberikan akurasi tinggi dalam memperkirakan temperatur pendingin berdasarkan parameter operasional seperti tegangan, arus, torsi, dan kecepatan motor. Evaluasi model menunjukkan performa yang sangat baik dalam menjaga keseimbangan antara bias dan varians, dengan nilai evaluasi koefisien determinasi (R^2), Mean Squared Error (MSE), dan Mean Absolute Error (MAE) yang mendukung reliabilitas model. Implementasi teknologi ini memberikan manfaat signifikan, termasuk pengurangan konsumsi energi melalui pendinginan adaptif, penghematan biaya operasional dengan optimalisasi penggunaan pendingin, serta peningkatan masa pakai komponen motor melalui pengelolaan suhu yang presisi. Sistem ini juga menawarkan keunggulan seperti deteksi dini potensi overheating, pengawasan berbasis cloud untuk analisis jarak jauh, dan respons otomatis dalam waktu nyata terhadap perubahan kondisi operasional. Dengan demikian, pengembangan model ini tidak hanya berkontribusi pada efisiensi dan keberlanjutan industri, tetapi juga mendukung upaya pengurangan jejak karbon dan penghematan sumber daya, menjadikannya solusi inovatif yang relevan dalam transisi menuju industri berbasis teknologi cerdas dan ramah lingkungan.

4.2. Potensi Pengembangan



Gambar 11. Skema Implementasi

Proyek kecerdasan buatan bertajuk “Prediksi Temperatur Pendingin Motor Listrik dengan K-Neighbours Regressor” memiliki potensi implementasi industri sebagaimana tertampil pada Gambar X di atas. Pada gambar tersebut, motor listrik terkoneksi dengan *temperature transmitter* (TT) yang memonitor temperatur kerja dari motor listrik. Hasil bacaan TT kemudian diunggah ke dalam *cloud-based data storage* untuk kemudian diolah oleh algoritma AI. Bila model AI memprediksi bahwa motor listrik akan mengalami *overheat*, maka model akan menginstruksikan *flow transmitter* (FT) untuk mengatur bukaan valve untuk mengalirkan pendingin (*coolant*) ke motor. Residu *coolant* kemudian diproses kembali untuk digunakan pada siklus pendinginan selanjutnya.

Dengan diterapkannya teknologi ini, maka dapat diperoleh *operational advantage* sebagai berikut:

1. Meningkatkan Efisiensi Operasional
 - Teknologi ini memungkinkan pengaturan pendinginan motor listrik secara otomatis berdasarkan prediksi kondisi kerja motor. Hal ini mengurangi pemborosan energi yang sering terjadi akibat pendinginan berlebih (*overcooling*) atau pemakaian pendingin yang tidak tepat waktu.
2. Meningkatkan Umur Motor Listrik
 - Dengan mencegah motor listrik mengalami *overheat*, komponen motor tidak akan cepat aus atau rusak. Ini memperpanjang masa pakai motor, sehingga mengurangi frekuensi perawatan dan penggantian.
3. Mengurangi Biaya Operasional
 - Prediksi berbasis AI membantu mengoptimalkan penggunaan coolant dan energi. Pengurangan pemborosan ini berdampak langsung pada penghematan biaya operasional, termasuk pengeluaran untuk pendingin dan konsumsi daya.
4. Meminimalkan Downtime Produksi

- Deteksi dini potensi overheating memungkinkan tindakan preventif sebelum terjadi kerusakan yang memerlukan perbaikan besar. Hal ini menjaga kelangsungan proses produksi dan mengurangi waktu henti (downtime).

5. Meningkatkan Keandalan Sistem

- Sistem prediksi berbasis AI memberikan solusi yang lebih andal dibandingkan metode manual atau berbasis aturan statis. Akurasi prediksi yang tinggi memungkinkan pengambilan keputusan yang lebih cepat dan tepat.

6. Mendukung Praktik Industri Ramah Lingkungan

- Dengan meminimalkan konsumsi energi dan mendaur ulang residu coolant, teknologi ini mendukung upaya industri untuk mengurangi jejak karbon (carbon footprint) dan mematuhi standar lingkungan.

7. Meningkatkan Kecepatan Respons

- Dengan integrasi langsung ke sistem kontrol, instruksi dari model AI untuk mengatur bukaan valve pendingin dilakukan secara real-time. Hal ini memungkinkan respons cepat terhadap perubahan kondisi motor.

8. Kemudahan Monitoring dan Analisis Jarak Jauh

- Data yang disimpan di cloud-based storage dapat diakses oleh tim operasional dan teknisi secara jarak jauh. Ini mendukung pengawasan dan analisis performa sistem tanpa harus berada di lokasi fisik.

DAFTAR PUSTAKA

- [1] A. Li, Y. Wang, and Z. Wang, "Motor Temperature Prediction with K-Nearest Neighbors and Convolutional Neural Networks," *CS229 Project*, Stanford University, 2019.
- [2] Y. Wang, Z. Wang, and A. Li, "Electric Motor Temperature Prediction with K-Nearest Neighbors and Linear Regression," *CS229 Project*, Stanford University, 2019.
- [3] Scikit-learn Team, "KNeighborsRegressor," *Scikit-learn Documentation*, 2024.
- [4] GeeksforGeeks, "K-Nearest Neighbors (KNN) Regression with Scikit-Learn," *GeeksforGeeks*, 2024.
- [5] D. Sun, "Lecture 11: K-Nearest Neighbors," Stanford University, 2024.
- A. Li, "Electric Motor Temperature Prediction," *GitHub*, 2020.
- [6] DataScienceBook.ca Team, "Chapter 7: Regression I: K-Nearest Neighbors," *DataScienceBook.ca*, 2024.
- [7] M. Y. R. Rangkuti, M. V. Alfansyuri, and W. Gunawan, "Penerapan Algoritma [8] K-Nearest Neighbor (KNN) dalam Memprediksi dan Menghitung Tingkat Akurasi Data Cuaca di Indonesia," *Jurnal HEXAGON*, vol. 3, no. 1, pp. 35–45, 2021.
- [9] Y. Li, "Applying k-Nearest Neighbors to Time Series Forecasting," *arXiv preprint*, Mar. 2021.
- [10] Frontiers in Big Data Team, "Random Kernel k-Nearest Neighbors Regression," *Frontiers in Big Data*, vol. 3, article 1402384, 2024.

LAMPIRAN

Lampiran 1. URL Video Presentasi

[Video Presentasi](#)

Lampiran 2. URL Video Demo Project

[Demo Project](#)

Lampiran 3. Code

[Code in Collab](#)